Diseño de Bases de Datos

Modelado y Calidad de Datos

Facultad de Informática

June 14, 2016

Bibliografía



Batini C. and Scannapieco M.
Data Quality: Concepts, Methodologies and Techniques.
Springer-Verlag, 2006

Contenido

1. Introducción
   - Qué conocemos hasta ahora?
   - Posibles Impactos
   - Concepto de Calidad de Datos
2. Calidad de Datos Basada en el Uso
   - Las 6 Reglas de Calidad de Datos
   - Programas de Calidad de Datos basados en su Uso
3. Dimensiones de Calidad de Datos
   - Qué son las Dimensiones?
   - Exactitud
   - Completitud
   - Consistencia
   - Dimensiones Relacionadas con el Tiempo
4. Enfoques para la la Calidad de Datos
   - Analogía de una BD
   - Formas de Enfrentar la Calidad de Datos

Contexto

- Hemos visto técnicas para lograr **Calidad** en el **Diseño de una Base de Datos**
  - Brindando una semántica precisa
  - Evitando información redundante y anomalías
  - Evitando valores nulos en las tuplas
  - Evitando la generación de datos falsos (spurious data)

Contexto

- Esta calidad se refiere al *esquema de la base de datos* y no a la **Calidad de los valores de los datos**
- Qué problemas podemos encontrar en la siguiente relación?

Id	Título	Director	Año	Versiones	AnõUltimaVersion
1	Casablanca	Weir	1942	3	1940
2	La Sociedad de los Poetas Muertos	Curtiz	1989	0	null
3	La Dma de Hierro	Lloyd	2012	0	null
4	Avatar	null	2009	0	2012

Table: Relación Película

Contexto

- Esta calidad se refiere al *esquema de la base de datos* y no a la **Calidad de los valores de los datos**
- Qué problemas podemos encontrar en la siguiente relación?

Id	Título	Director	Año	Versiones	AnõUltimaVersion
1	Casablanca	Weir	1942	3	1940
2	La Sociedad de los Poetas Muertos	Curtiz	1989	0	null
3	La Dma de Hierro	Lloyd	2012	0	null
4	Avatar	null	2009	0	2012

Table: Relación Película

Contexto

- Esta calidad se refiere al *esquema de la base de datos* y no a la **Calidad de los valores de los datos**
- Qué problemas podemos encontrar en la siguiente relación?

Id	Título	Director	Año	Versiones	AnõUltimaVersion
1	Casablanca	Weir	1942	3	1940
2	La Sociedad de los Poetas Muertos	Curtiz	1989	0	null
3	La Dma de Hierro	Lloyd	2012	0	null
4	Avatar	null	2009	0	2012

Table: Relación Película

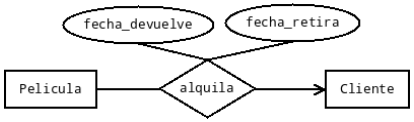
Contexto

- Esta calidad se refiere al *esquema de la base de datos* y no a la **Calidad de los valores de los datos**
- Qué problemas podemos encontrar en la siguiente relación?

Id	Título	Director	Año	Versiones	AnõUltimaVersion
1	Casablanca	Weir	1942	3	1940
2	La Sociedad de los Poetas Muertos	Curtiz	1989	0	null
3	La Dma de Hierro	Lloyd	2012	0	null
4	Avatar	null	2009	0	2012

Table: Relación Película

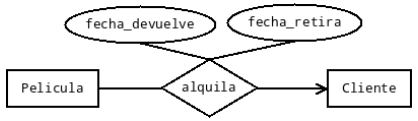
Impactos de la Calidad de Datos I



Id_Pelicula	Id_Cliente	fecha_retira	fecha_devuelve
1	C1	10/11/2012	10/11/2014
2	C2	28/11/2014	30/11/2014
2	C3	29/11/2014	null
3	C2	01/03/2015	null

Table: Relación Alquila

Impactos de la Calidad de Datos II

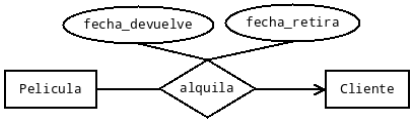


Id_Pelicula	Id_Cliente	fecha_retira	fecha_devuelve
1	C1	10/11/2012	10/11/2014
2	C2	28/11/2014	30/11/2014
2	C3	29/11/2014	null
3	C2	01/03/2015	null

Table: Relación Alquila

- Impacto sobre las *Operaciones*
  - *Clientes insatisfechos*: recargo por devolución tardía, película nunca devuelta, película no devuelta prestada
  - *Incremento en el costo operacional*: tiempo perdido en detectar y corregir errores

Impactos de la Calidad de Datos II

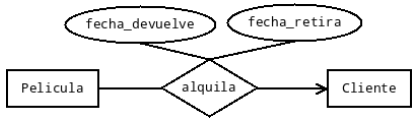


Id_Pelicula	Id_Cliente	fecha_retira	fecha_devuelve
1	C1	10/11/2012	10/11/2014
2	C2	28/11/2014	30/11/2014
2	C3	29/11/2014	null
3	C2	01/03/2015	null

Table: Relación Alquila

- Impacto sobre las *Operaciones*
  - *Empleados insatisfechos*: no confian en los datos, reciben reclamos de los clientes, no conocen cierta información

Impactos de la Calidad de Datos III

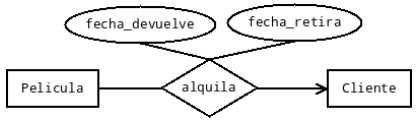


Id_Pelicula	Id_Cliente	fecha_retira	fecha_devuelve
1	C1	10/11/2012	10/11/2014
2	C2	28/11/2014	30/11/2014
2	C3	29/11/2014	null
3	C2	01/03/2015	null

Table: Relación Alquila

- Impacto en las *Toma de Decisiones*
  - *Malas decisiones gerenciales*: *las decisiones no van a ser mejores que los datos en las que están basadas*
  - *No permite el uso de herramientas automáticas*: herramientas que se utilizan como soporte para la toma de decisiones

Impactos de la Calidad de Datos III



Id_Pelicula	Id_Cliente	fecha_retira	fecha_devuelve
1	C1	10/11/2012	10/11/2014
2	C2	28/11/2014	30/11/2014
2	C3	29/11/2014	null
3	C2	01/03/2015	null

Table: Relación Alquila

- Impacto en las *Toma de Decisiones*
  - *No permite la evaluación de resultados*: por ejemplo comprar mas películas, dar promociones
  - *Sensación de insatisfacción*: sucursales del video club que comparten información

Definición

Hay muchas definiciones del término Calidad de Datos, una de ellas es:

La Calidad de los datos es la capacidad de los datos de cumplir con su propósito en un determinado contexto. Se puede resumir como **"Capacidad de Uso"**.

Tayi, G. K. and Ballou, D. P.
Examining data quality.
Communications of the ACM, Volume 41 Issue 2, Feb. 1998. Pages 54-57

Definición

- Qué significa **"Capacidad de Uso"**?
  - El concepto de calidad de datos es *relativo*
  - Datos considerados con calidad para un uso apropiado pueden no poseer la suficiente calidad para otros usos

Documento	Nombre	Apellido	Dirección
22.567.345	Lucia	Gomez	Av Argentina 320, Neuquén
15.720.006	Roberto	Martinez	Cipolletti

Table: Relación Cliente

Definición

- Qué significa **"Capacidad de Uso"**?
  - El concepto de calidad de datos es *relativo*
  - Datos considerados con calidad para un uso apropiado pueden no poseer la suficiente calidad para otros usos

Documento	Nombre	Apellido	Dirección
22.567.345	Lucia	Gomez	Av Argentina 320, Neuquén
15.720.006	Roberto	Martinez	Cipolletti

Table: Relación Cliente

Contenido

1. Introducción
   - Qué conocemos hasta ahora?
   - Posibles Impactos
   - Concepto de Calidad de Datos
2. Calidad de Datos Basada en el Uso
   - Las 6 Reglas de Calidad de Datos
   - Programas de Calidad de Datos basados en su Uso
3. Dimensiones de Calidad de Datos
   - Qué son las Dimensiones?
   - Exactitud
   - Completitud
   - Consistencia
   - Dimensiones Relacionadas con el Tiempo
4. Enfoques para la la Calidad de Datos
   - Analogía de una BD
   - Formas de Enfrentar la Calidad de Datos

Reglas basadas en el uso del dato

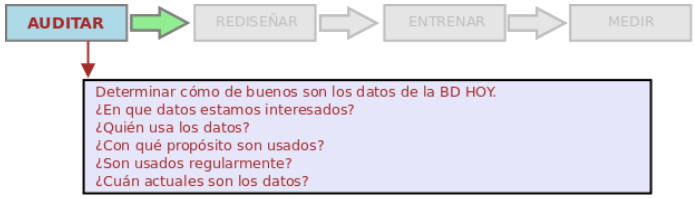
- **DQ1**: Los datos que no son usados no se mantienen correctos por mucho tiempo
- **DQ2**: La calidad de los datos en un sistema de información esta en función de su uso, no de su obtención
- **DQ3**: La calidad de los datos no será mejor que su uso más riguroso
- **DQ4**: La calidad de los datos tienden a volverse peores con el paso del tiempo
- **DQ5**: La baja probabilidad de que un dato cambio repercutirá en su calidad
- **DQ6**: Las reglas de calidad de datos se aplican tanto a los datos como a los metadatos (datos sobe los datos)



Orr K.
Data Quality and Systems Theory.
Communications of the ACM Volume 41 Issue 2, 1998

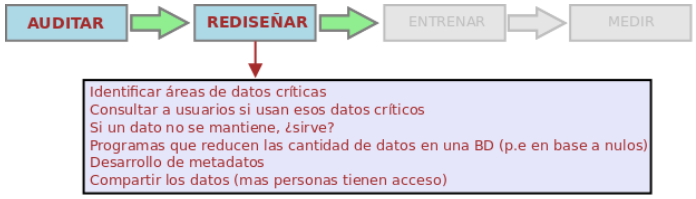
Fomentar el uso del dato

La calidad de los datos es una **función de su uso**. Por lo tanto debemos **MEJORAR SU USO**



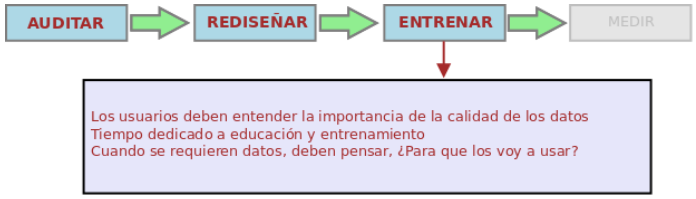
Fomentar el uso del dato

La calidad de los datos es una **función de su uso**. Por lo tanto debemos **MEJORAR SU USO**



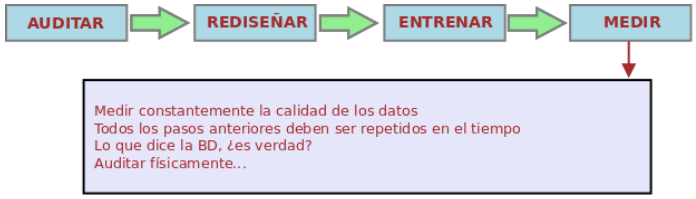
Fomentar el uso del dato

La calidad de los datos es una **función de su uso**. Por lo tanto debemos **MEJORAR SU USO**



Fomentar el uso del dato

La calidad de los datos es una **función de su uso**. Por lo tanto debemos **MEJORAR SU USO**



Fomentar el uso del dato

- Debemos **MEJORAR SU USO**
- Identificar qué **personas** usan qué **datos**
- Determinar **qué usos** le dan a cada dato
- Por cada dato, evaluar la calidad de acuerdo a diferentes **atributos o dimensiones**

Contenido

1. Introducción
   - Qué conocemos hasta ahora?
   - Posibles Impactos
   - Concepto de Calidad de Datos
2. Calidad de Datos Basada en el Uso
   - Las 6 Reglas de Calidad de Datos
   - Programas de Calidad de Datos basados en su Uso
3. Dimensiones de Calidad de Datos
   - Qué son las Dimensiones?
   - Exactitud
   - Completitud
   - Consistencia
   - Dimensiones Relacionadas con el Tiempo
4. Enfoques para la la Calidad de Datos
   - Analogía de una BD
   - Formas de Enfrentar la Calidad de Datos

Las dimensiones de calidad

- Las **dimensiones** son atributos de calidad deseables para los datos
- Cada **dimensión** captura un aspecto específico incluído dentro de los requerimientos de calidad de datos
- Las dimensiones de calidad se pueden referir tanto al **esquema de datos** o a los **valores de los datos**
- Así, la **Calidad de Datos** puede ser vista como un concepto **multidimensional**, es decir, definido mediante las diferentes dimensiones

Dimensiónes de Calidad de Datos: Exactitud

- ¿Representan los datos exactamente la realidad o fuentes verificables? La exactitud del dato esta relacionada con su fuente. El nivel de correspondencia entre el dato y el mundo real
- **Exactitud Sintáctica**: Es la cercanía de un valor *v* a los elementos del dominio en el cual está definido
  - No nos interesa comparar *v* con su valor real, sino en verificar si *v* es un valor permitido en el dominio.
  - Por ejemplo, si *v=Macarena*, *v* se considera sintácticamente correcto ya que está permitido dentro de los valores del dominio, aunque *Macarena* no exista como persona en el dominio real que se esta modelando

Dimensiónes de Calidad de Datos: Exactitud Sintáctica

Id	Título	Director	Año	Versiones	AnõUltimaVersion
1	Casablanca	Weir	1942	3	1940
2	La Sociedad de los Poetas Muertos	Curtiz	1989	0	null
3	La Dma de Hierro	Lloyd	2012	0	null
4	Avatar	null	2009	0	2012

Table: Relación Película

Dimensiónes de Calidad de Datos: Exactitud Semántica

- **Exactitud Semántica**: Es la cercanía de un valor *v* a su valor en el mundo real

Id	Título	Director	Año	Versiones	AnõUltimaVersion
1	Casablanca	Weir	1942	3	1940
2	La Sociedad de los Poetas Muertos	Curtiz	1989	0	null
3	La Dma de Hierro	Lloyd	2012	0	null
4	Avatar	null	2009	0	2012

Table: Relación Película

Dimensiónes de Calidad de Datos: Completitud I

- ¿Todos los datos necesarios están presentes? ¿Qué cantidad de datos no están presentes?

Documento	Nombre	Apellido	Dirección
22.567.345	Lucia	Gomez	Av Argentina 320, Neuquén
15.720.006	Roberto	Martinez	Cipolletti

Table: Relación Cliente

- ¿Qué podemos decir con respecto al atributo **Dirección**?

Dimensiónes de Calidad de Datos: Completitud II

Documento	Nombre	Apellido	Calle	Número	Ciudad	Email
22.567.345	Lucia	Gomez	Av Argentina	320	Neuquén	lucia.gomez@gmail.com
15.720.006	Roberto	Martinez	null	null	null	null
20.002.957	Martín	Barragan	Buenos Aires	1200	Cipolletti	null

Table: Relación Cliente

Dimensiónes de Calidad de Datos: Completitud III

Documento	Nombre	Apellido	Calle	Número	Ciudad	Email
22.567.345	Lucia	Gomez	Av Argentina	320	Neuquén	lucia.gomez@gmail.com
15.720.006	Roberto	Martinez	null	null	null	null
20.002.957	Martín	Barragan	Buenos Aires	1200	Cipolletti	null

Table: Relación Cliente

Dimensiónes de Calidad de Datos: Consistencia

¿Los datos fueron consistentemente definidos y entendidos? Requiere disciplina en el tiempo. Se deben fijar protocolos y estándares para los datos

Documento	Nombre	Apellido	Calle	Número	Ciudad	Género
22.567.345	Lucia	Gomez	Av Argentina	320	Neuquén	Femenino
15.720.006	Roberto	Martinez	Misiones	130	Gral Roca	M
20.002.957	Martín	Barragan	Buenos Aires	1200	Cipolletti	Masculino
15.590.310	Romina	Sanchez	La Rioja	200	Neuquén	Mujer
35.590.310	Laura	Alonso	Rivadavia	1345	Neuquén	F

Table: Relación Cliente

Dimensiónes de Calidad de Datos: Consistencia II

A su vez se analizan las **reglas semánticas** definidas sobre un conjunto de datos que pueden incluir restricciones del dominio de un **único** o **múltiples atributos**

Documento	Nombre	Apellido	FechaNacimiento	FechaIngreso	Salario
22.567.345	Lucia	Gomez	29-02-1971	01-02-1999	4.000
15.720.006	Roberto	Martinez	28-10-1945	01-13-1950	5.500

Table: Relación Empleado

Dimensiónes de Calidad de Datos: Consistencia III

A su vez se analizan las **reglas semánticas** definidas sobre un conjunto de datos que pueden incluir restricciones del dominio de un **único** o **múltiples atributos**

Documento	Nombre	Apellido	FechaNacimiento	FechaIngreso	Salario
22.567.345	Lucia	Gomez	28-02-1971	01-02-1999	4.000
15.720.006	Roberto	Martinez	28-10-1945	01-13-1950	5.500

Table: Relación Empleado

Dimensiónes de Calidad de Datos: Relacionadas con el Tiempo

- **Actualidad**: ¿Cuánto transcurre hasta que se actualizan los datos? *Por ejemplo la dirección de una Persona*
- **Volatibilidad**: La frecuencia por el cual el dato se mantiene válido. *Por ejemplo, fecha de nacimiento vs. stock de productos*
- **Temporalidad**: ¿Cuán actuales son los datos para realizar una tarea? Pueden ser datos útiles pero no estar disponibles cuando se necesitan. *Por ejemplo fecha de parciales*

Contenido

1. Introducción
   - Qué conocemos hasta ahora?
   - Posibles Impactos
   - Concepto de Calidad de Datos
2. Calidad de Datos Basada en el Uso
   - Las 6 Reglas de Calidad de Datos
   - Programas de Calidad de Datos basados en su Uso
3. Dimensiones de Calidad de Datos
   - Qué son las Dimensiones?
   - Exactitud
   - Completitud
   - Consistencia
   - Dimensiones Relacionadas con el Tiempo
4. Enfoques para la la Calidad de Datos
   - Analogía de una BD
   - Formas de Enfrentar la Calidad de Datos

La Base de Datos como un Lago



Agua del lago= Datos - Ríos= Cadenas de Información que crean los datos Fábricas= Fuentes de contaminación - Persona tomando agua= Consumidor de datos

La Base de Datos como un Lago

- Ante la **contaminación** del lago podemos:
  1. No hacer caso de los contaminantes y tratar a las personas que se enferman por el agua del lago
  2. Filtrar el agua del lago, eliminar las fuentes de contaminación y poner el agua de nuevo en el lago
  3. Filtrar pequeñas cantidades de agua cada día. Por ejemplo, filtrar el agua en el punto de entrada de los ríos al lago. Así, sólo el agua limpia entra en el lago. O se podría filtrar el agua justo antes de su consumo
  4. Identificar las fuentes de contaminación y eliminarlas (o al menos mitigarlas)

Enfrentarse a la realidad

- Del mismo modo, frente a una **base de datos contaminada (con una pobre calidad)** tenemos las mismas 4 opciones:
  1. Tratar con los **impactos que generan los datos erróneos**, lo cual puede incluir acciones como corregir malas decisiones y/o calmar clientes enojados (devolviendo dinero)
  2. Realizar de alguna manera **limpiezas de la base de datos** mediante la exploración de los datos, la comparación con otras bases de datos para encontrar discrepancias, la ejecución de pruebas automatizadas para identificar datos que no se ajusten a las reglas de negocio
  3. Realizar diariamente **pequeñas limpiezas de la base de datos** como parte de las operaciones diarias. As, se podrían limpiar los datos a la entrada en una base de datos o limpiarlos antes de usarlos
  4. Encontrar las **fuentes de datos erróneas** en las cadenas de información que crean los nuevos datos

Enfrentarse a la realidad

- Una organización que **no hace absolutamente nada** con respecto a la calidad de los datos, ha elegido implícitamente la **opción 1**
- La **opción 2 es la seleccionada más frecuentemente**. *Hay un gran número de herramientas informáticas que permiten automatizar la detección de errores*. Luego se deben corregir los errores detectados (muchas veces mediante la intuición o definiendo reglas fijas)
  - *No funciona a largo plazo. Nuevos datos incorrectos se crean con mucha rapidez. La limpieza nunca termina*
  - *Muy caro y genera una falsa sensación de seguridad*
  - *Las herramientas informáticas encuentran generalmente sólo errores obvios*

Enfrentarse a la realidad

- La **opción 3** abarca la **limpieza de los datos nuevos creados diariamente** y la **limpieza de los datos antes de ser utilizados**. Nuevamente, la limpieza simplemente se convierte en parte de las operaciones diarias. Las organizaciones que dependen de los datos más recientes (por ejemplo, el precio de un valor a una casa) a menudo eligen este enfoque.
- La **opción 4** consiste en identificar y detectar las causas de los errores y eliminarlos. En vez de basarse en la detección y corrección, se basa en la **prevención**.
  - *Provee ventajas a largo plazo*
  - *Es mas costoso y se debe pensar en los procesos y fuentes de información*
  - *Las organizaciones generalmente están pensando en el día a día*

Próximamente en la Carrera...

- Más Dimensiones de Calidad
- Modelos para Calidad de Datos
  - Extensiones de los modelos Entidad-Relación
  - Total Data Quality Management (TDQM)
  - IP-MAP


Wang, R. Y.
A Product Perspective on Total Data Quality Management.
Communications of the ACM, Volume 41 Issue 2, Feb. 1998. Pages 58-65


Shankaranarayan, G. and Wang, R. Y. and Ziad, M.
Modeling the Manufacture of an Information Product with IP-MAP.
In Proc. 5th International Conference on Information Quality, 2000

Resumiendo...

- La **calidad de datos** es un concepto muy importante que debe considerarse cuidadosamente
- Una **mala calidad de datos** puede generar el fracaso total de la utilidad de una BD
- Los datos son medidos y evaluados de acuerdo al **uso** de los mismos
- La calidad de datos es un concepto **multidimensional**
- Hay diferentes enfoques de enfrentar los problemas de calidad, **detección y corrección vs. prevención**