DISEÑO DE BASES DE DATOS

UNIDAD VI: TEORÍA Y DISEÑO DE BASES DE DATOS RELACIONALES

Introducción a la Minería de Datos



Departamento Ingeniería de Sistemas
Facultad de Informática
Universidad Nacional del Comahue



Concepto

La **MINERÍA DE DATOS** extrae patrones o información interesante (no trivial, implícita, previamente desconocida, potencialmente útil) desde datos en grandes bases de datos

LA MINERÍA DE DATOS "ANALIZA" LOS DATOS

Concepto I

- Intenta descubrir **reglas** y **patrones** desde los datos
- Trabaja con grandes volúmenes de datos almacenados en disco
- Realiza "**Descubrimiento de Conocimiento en Bases de Datos**" (Knowledge discovery in databases (KDD))

Concepto II

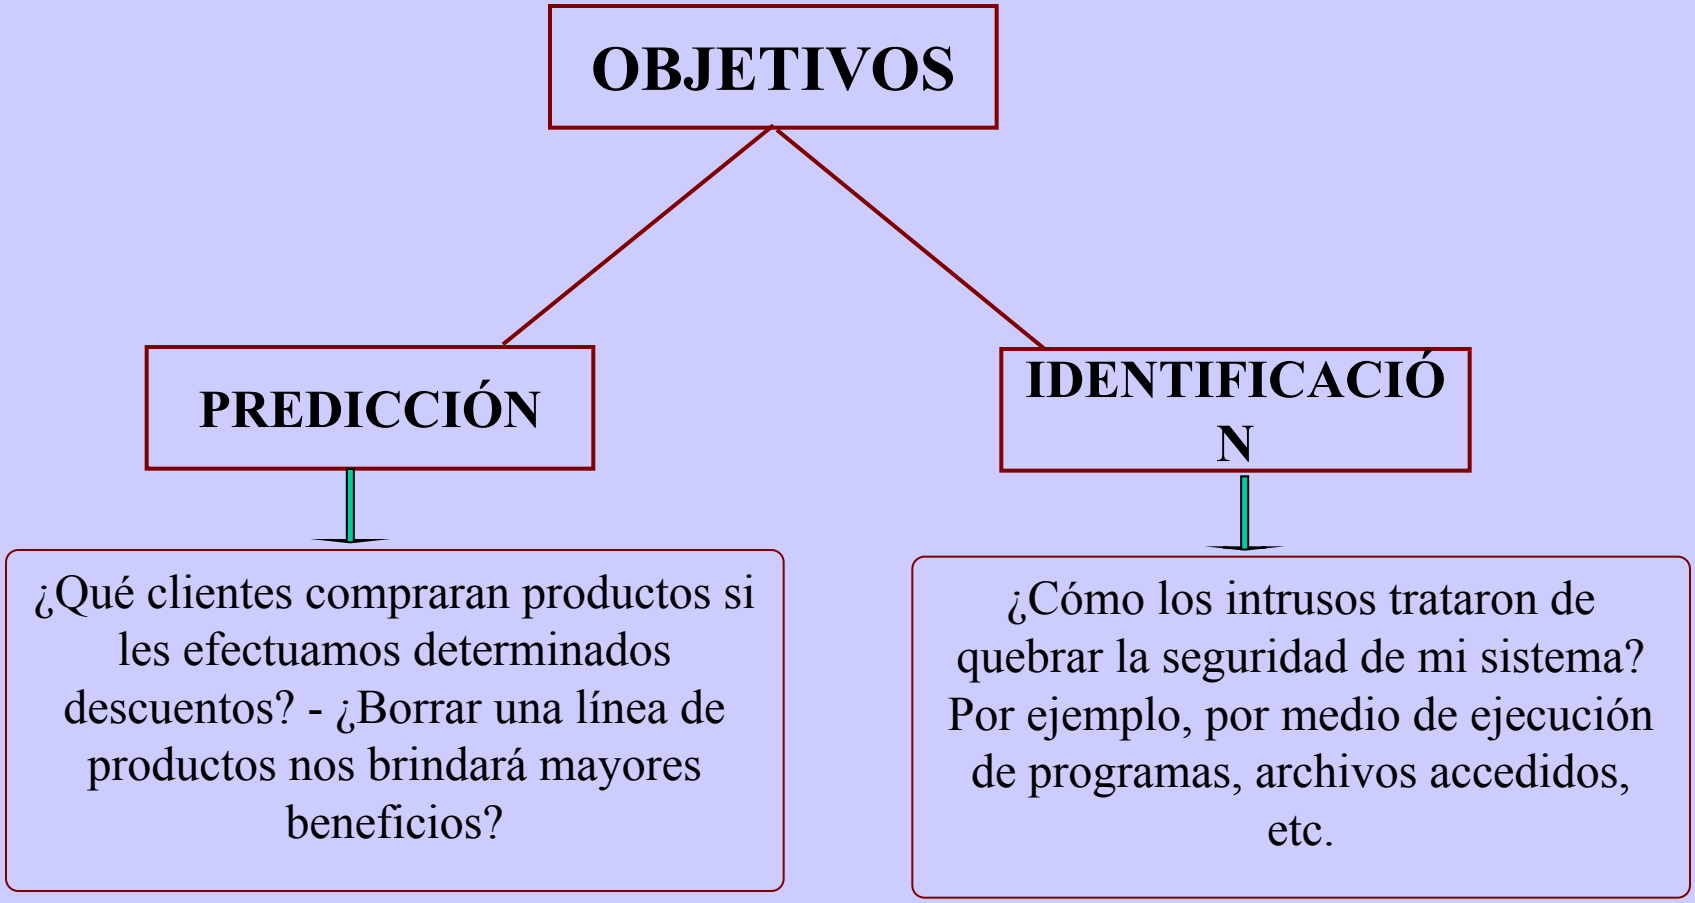
- La **Minería de Datos** es diferente a las herramientas de consulta
- Las herramientas de consulta permiten hacerle preguntas al SGBD y a las herramientas de Minería de Datos
  - **¿Cuántos kilos de manzanas se produjeron en Neuquén vs. Río Negro?**
- El usuario que efectúa esta consulta sabe (probablemente) que los volúmenes de venta varias de acuerdo a las zonas (clima, suelo, etc.). **Efectúa suposiciones.**

Concepto III

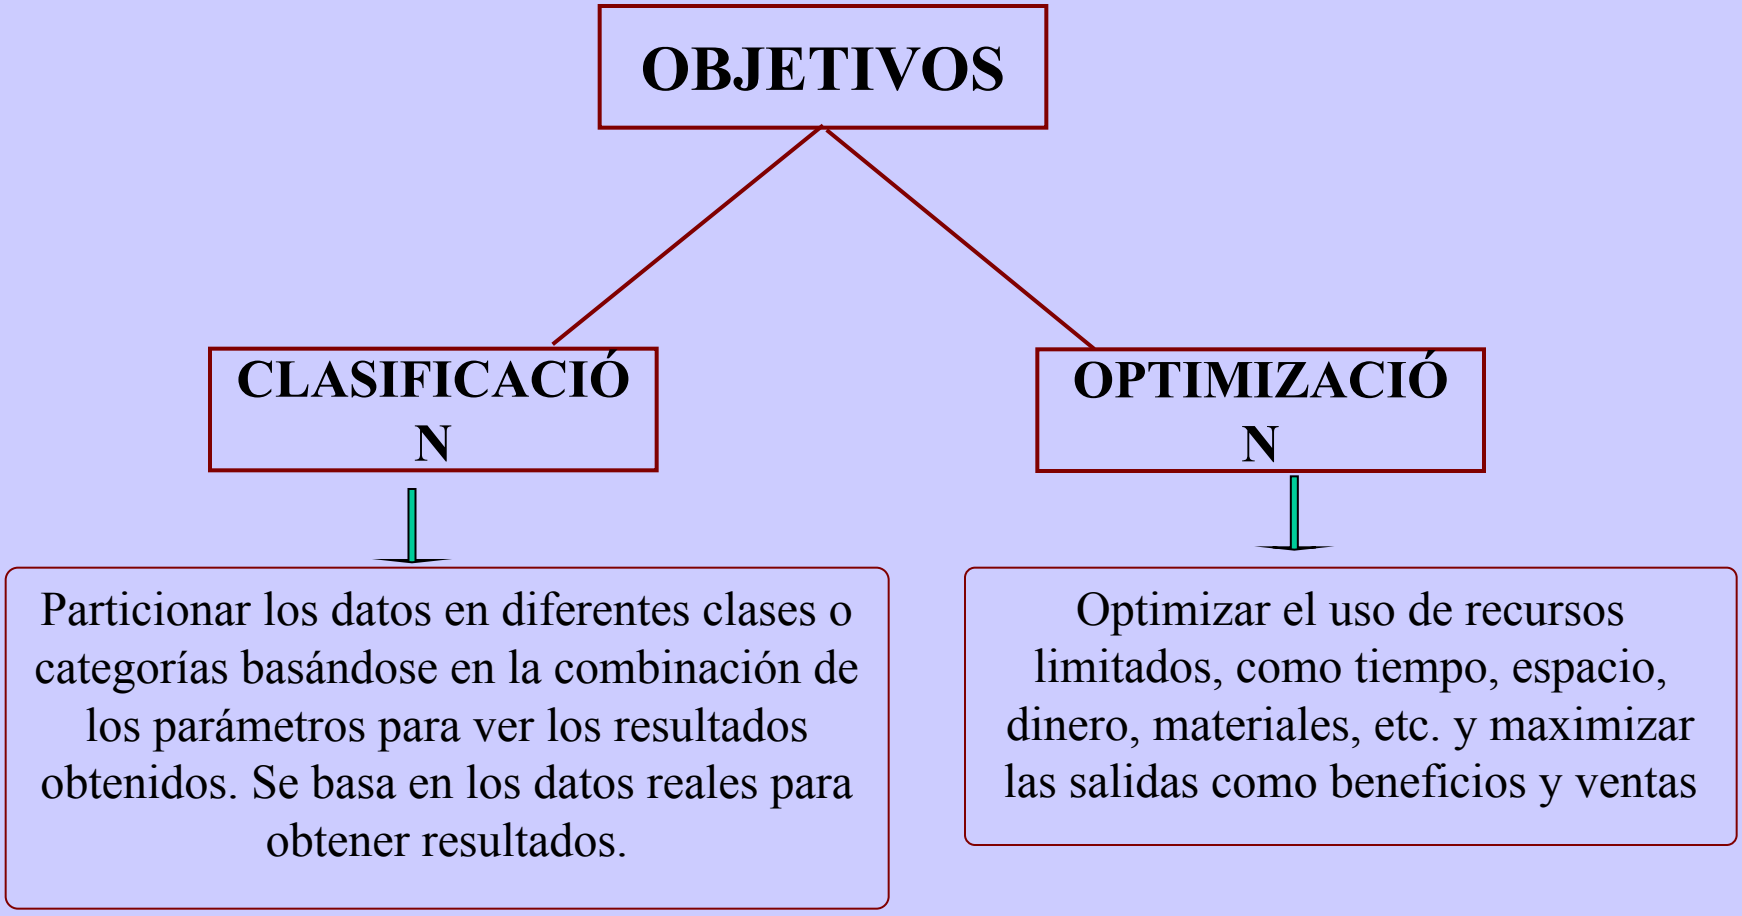
- Con respecto a esta pregunta una herramienta de **Minería de Datos** tratará de determinar los factores mas significativos que produzcan volúmenes de producción altos, medios o bajos.

- Una herramienta de **Minería de Datos** no requiere hacer suposiciones: **TRATARÁ DE DESCUBRIR RELACIONES Y PATRONES ESCONDIDOS QUE NO SON SIEMPRE OBVIOS.**

Objetivos


OBJETIVOS
PREDICCIÓN
IDENTIFICACIÓN
¿Qué clientes compraran productos si les efectuamos determinados descuentos? - ¿Borrar una línea de productos nos brindará mayores beneficios?
¿Cómo los intrusos trataron de quebrar la seguridad de mi sistema? Por ejemplo, por medio de ejecución de programas, archivos accedidos, etc.

Objetivos


OBJETIVOS
CLASIFICACIÓN
OPTIMIZACIÓN
Particionar los datos en diferentes clases o categorías basándose en la combinación de los parámetros para ver los resultados obtenidos. Se basa en los datos reales para obtener resultados.
Optimizar el uso de recursos limitados, como tiempo, espacio, dinero, materiales, etc. y maximizar las salidas como beneficios y ventas

Enfoques

- Dos enfoques para la Minería de Datos
  - **Aprendizaje Supervisado**
  - **Aprendizaje no Supervisado**

Aprendizaje Supervisado

- Es el aprendizaje a partir de ejemplos, el instructor o experto define clases (leal vs. perdido) y provee ejemplos de cada una. El sistema debe obtener una descripción para cada clase.
- Cuando el instructor define una única clase, provee ejemplos positivos (pertenecen a la clase) y negativos (no pertenecen a la clase)
  - Un analista de telecomunicaciones quiere entender porque posee clientes leales y existen otros no lo son. Entonces quiere predecir cuales clientes de su compañía son los más desleales (es decir, se irán a la competencia). Con esto en mente, el analista puede construir un modelo derivado de datos históricos de sus clientes leales vs aquellos que lo han dejado.
  - Un buen modelo le permitirá entender mejor a sus clientes y le servirá para predecir cuales clientes se quedarán y cuales se irán.

Aprendizaje Supervisado

Datos que identifican al cliente

Nombre columna	Tipo de dato	Valor	Descripción
Id_cliente	Numérico	Valores únicos	Identificador único para el cliente
Tiempo_de_uso	Numérico	Valores enteros	Cantidad de días que un cliente ha estado con la compañía
Línea_de_uso	Caracter	Muy alto, Alto, Medio, Bajo, Muy bajo	Minutos usados por el cliente el último mes
Tipo_de_uso	Caracter	Creciente, Igual, Decreciente	Un indicador de uso del cliente los últimos seis meses
Indicador_de_estado	Caracter	Alto, Justo, Bajo, Desconocido	Resultados del examen sobre la satisfacción del cliente
Tipo_de_cliente	Caracter	Leal, Perdido	Esta actualmente el cliente con la compañía (leal)? O no (perdido)?

Aprendizaje Supervisado

- Este modelo *implícitamente* requiere el conocimiento cuales clientes se han mantenido leales y cuales no
- Por esto la minería se llama **"Aprendizaje Supervisado"**
- Los ejemplos de entrenamiento se etiquetan con la clase actual (leal, perdido)
- También se podría hacer un estudio de las características del cliente basándose en el indicador de satisfacción

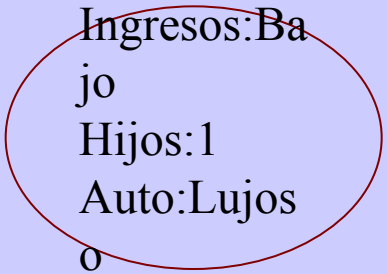
Aprendizaje No Supervisado

- Este estudio se denomina **"Agrupamiento" (Clustering)**
- Es un método que agrupa filas de datos que comparten patrones similares
- Es el aprendizaje a partir de observaciones y descubrimientos
- El sistema debe agrupar los conceptos sin ayuda alguna de un instructor o experto
- El sistema recibe los ejemplos, pero no se predefine ninguna clase. Por lo tanto, debe observar los ejemplos y buscan características en común que permitan formar grupos.
- Como resultado, este tipo de aprendizaje genera un conjunto de descripciones de clases

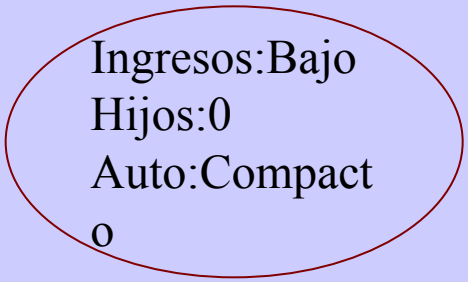
Aprendizaje No Supervisado

- Un grupo de vendedores quiere conocer las similitudes que existen entre sus clientes para poder crear y entender diferentes grupos de ventas y mercado.
- Las técnicas de Agrupamiento buscan similitudes y diferencias dentro de un conjunto de datos y agrupan las similitudes en un mismo grupo o segmento
  - Por ejemplo, pueden haber: clientes sin hijos, clientes con ingresos bajos, clientes con solo un padre
- Durante el proceso de descubrimiento estas diferencias son usadas para separar los datos en diferentes grupos

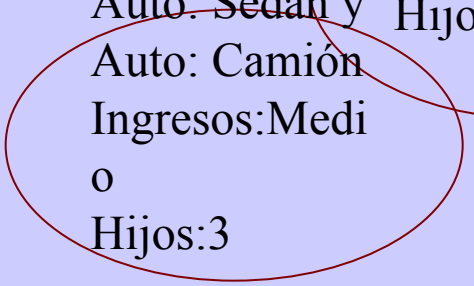
Aprendizaje No Supervisado



Grupo 1



Grupo 2



Grupo 3



Grupo 4

Por qué usar MD?

- **Marketing Directo**
  - Permite predecir que tipos de personas preferirán ciertos productos
  - Esto les permite a las empresas ahorrar gran cantidad de dinero y tiempo en tareas de marketing
  - Por ejemplo, vendedores por correo directo utilizan varias técnicas de minería de datos para reducir gastos, enviando correos a aquellos clientes calificados como potenciales en vez de enviar correos a una lista de millones de clientes

Por qué usar MD?

- **Análisis de Tendencias**
  - Entender tendencias en el mercado es obviamente una ventaja estratégica ya que es útil para reducir costos y tiempo
  - Instituciones financieras desean reconocer cambios en las formas en que los clientes efectúan depósitos y retiros de dinero
  - Los Minoristas quieren conocer que productos prefieren comprar las personas (Análisis de mercado)
  - Por ejemplo Wal-Mart utiliza minería de datos para análisis de tendencias

Por qué usar MD?

- **Detección de Fraudes**
  - Con técnicas de Minería de Datos podemos modelar cuales demandas de seguro, llamadas de teléfonos celulares, o compras con tarjetas de créditos son probables que sean fraudulentas
  - Muchas compañías que proporcionan tarjetas de créditos utilizan programas de minería de datos para modelar y entender los fraudes con las tarjetas

El proceso para MD

1) Preparación de los datos
2) Definición de un estudio
3) Lectura de datos y construcción del modelo
4) Compresión del modelo
5) Uso del conocimiento descubierto

El proceso para MD

1. **Preparación de los Datos**
   - Es el CORAZÓN del proceso de Minería de Datos
   - Por ejemplo si queremos saber qué clientes responderán a una campaña de comercialización directa, necesitamos datos sobre los clientes que hayan previamente respondido a avisos publicitarios. Pero si solo tenemos el nombre y la dirección de los clientes es muy difícil sacar conclusiones.
   - Información útil es en cambio: edad del cliente, nivel de ingresos, tipos de intereses, etc.
   - Este tipo de información puede ser comprada, pero para explorarla debe ser mezclada

El proceso para MD

1. **Preparación de los Datos**

- Limpieza de Datos
  - Diferentes formas de escribir la misma cosa. “Coca-Cola”, “Coca”, “Cola”. En realidad se refieren a lo mismo pero no son reconocidos como tal
  - Datos que se vencen, como las direcciones de correo debido a que las personas cambias de correo regularmente.
  - Problemas tipográficos en los datos. “Argentina” y “Argnetina “

El proceso para MD

- Valores Faltantes
  - Por ejemplo tuplas que posean valores nulos en algunos campos. Si existen muchos valores incompletos en una tupla va a ser mas difícil obtener información útil o hacer predicciones
- Derivación

compañía	maximo_gastado_94	maximo_gastado_95
WalMart	4.254.564	5.123.458
Jumbo	5.256.471	5.456.987



compañía	$_diferencia_gastos_94-95
WalMart	868.894
Jumbo	200.516

El proceso para MD

2. Definición de un Estudio

- Según el método de minería utilizado:
  - *Para Aprendizaje Supervisado*
    - Definir una meta (entender que hace que mis clientes se queden en mi compañía o que la dejen.)
    - Elegir una variable dependiente o salida que caracterice un aspecto de nuestra meta (el campo tipo_de_cliente (Leal-Perdido)
    - Especificar campos que nos serán útiles para nuestro estudio (línea_de_uso, indicador_de_estado, etc.)

El proceso para MD

2. Definición de un Estudio

- Según el método de minería utilizado:
  - *Para Aprendizaje No Supervisado*
    - La meta es agrupar tipos de datos o identificar excepciones en un conjunto de datos
    - Agrupar conjuntos de datos es útil para técnicas de marketing
    - Agrupar excepciones es útil para descubrir datos fraudulentos o incorrectos

El proceso para MD

2. Definición de un Estudio

- Tamaño de la muestra de datos para especificar el estudio
- No es siempre necesario explorar todo el conjunto de datos
- Se pueden elegir solo un conjunto de filas
- Pero es difícil asegurarse que las elegidas representen todo el conjunto

El proceso para MD

3. Lectura de datos y construcción del modelo

- Una vez definido el estudio, un producto (software) de minería de datos lee los datos y construye un modelo
- Un modelo resume grandes cantidades de datos en indicadores
- Algunos indicadores que varios modelos acumulan son:
  - ***Frecuencias***: muestran cómo ocurre un cierto valor. Es decir, el 40% de los clientes que dejan la compañía tienen un valor Bajo en el indicador_de_estado
  - ***Pesos***: como algunas entradas indican la ocurrencia de ciertas salidas. Por ejemplo, podríamos llegar a la conclusión de que el valor Bajo en el campo indicador_de_estado tiene un alto peso o impacto en los clientes perdidos

El proceso para MD

3. Lectura de datos y construcción del modelo

- Mas indicadores:
  - ***Conjunciones***: muchas veces algunas entradas tienen mas peso juntas que separadas. Por ejemplo, puede no ser verdadero que el sexo masculino sea mas leal, pero si que las personas de sexo masculino, que tengan mascotas y que les guste esquiar sean mas leales
  - ***Diferenciación***: cuánto más importante es a un resultado un criterio de entrada que otro. Por ejemplo, un vendedor quiere conocer que jugadores de hockey son mas probables que compren sus productos, pero si los jugadores están mas predispuestos a comprar productos de un competidor, lo mas probable es que no se use este hecho

El proceso para MD

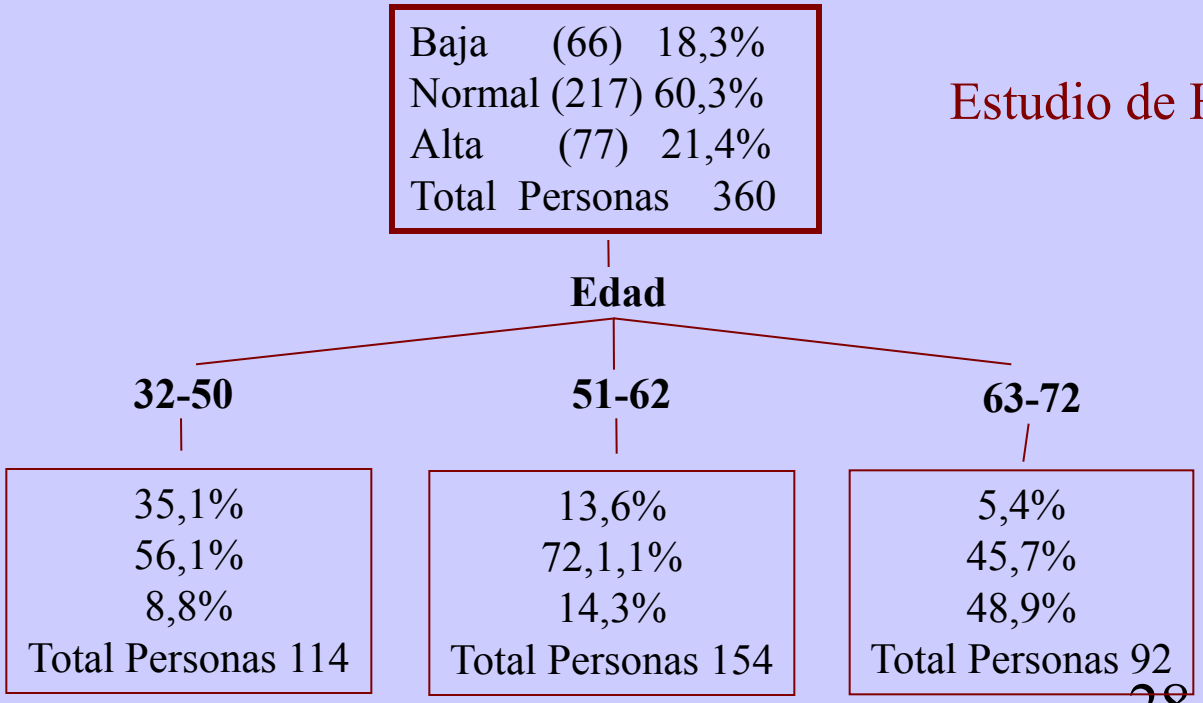
3. Lectura de datos y construcción del modelo

- Ruido:
  - Los modelos construidos muchas veces serán imperfectos debido a anomalías encontradas en los conjuntos de datos.
  - Existen filtros para suavizar el impacto del ruido en los conjuntos de datos y mejorar la correctitud del modelo
  - Muchos modelos poseen topes que limitan la cantidad de ruido aceptada en ellos

El proceso para MD

4. Compresión del Modelo

- Debe ser visto de acuerdo al modelo de Minería de Datos elegido y como se representan los datos



Estudio de Hipertensión

El proceso para MD

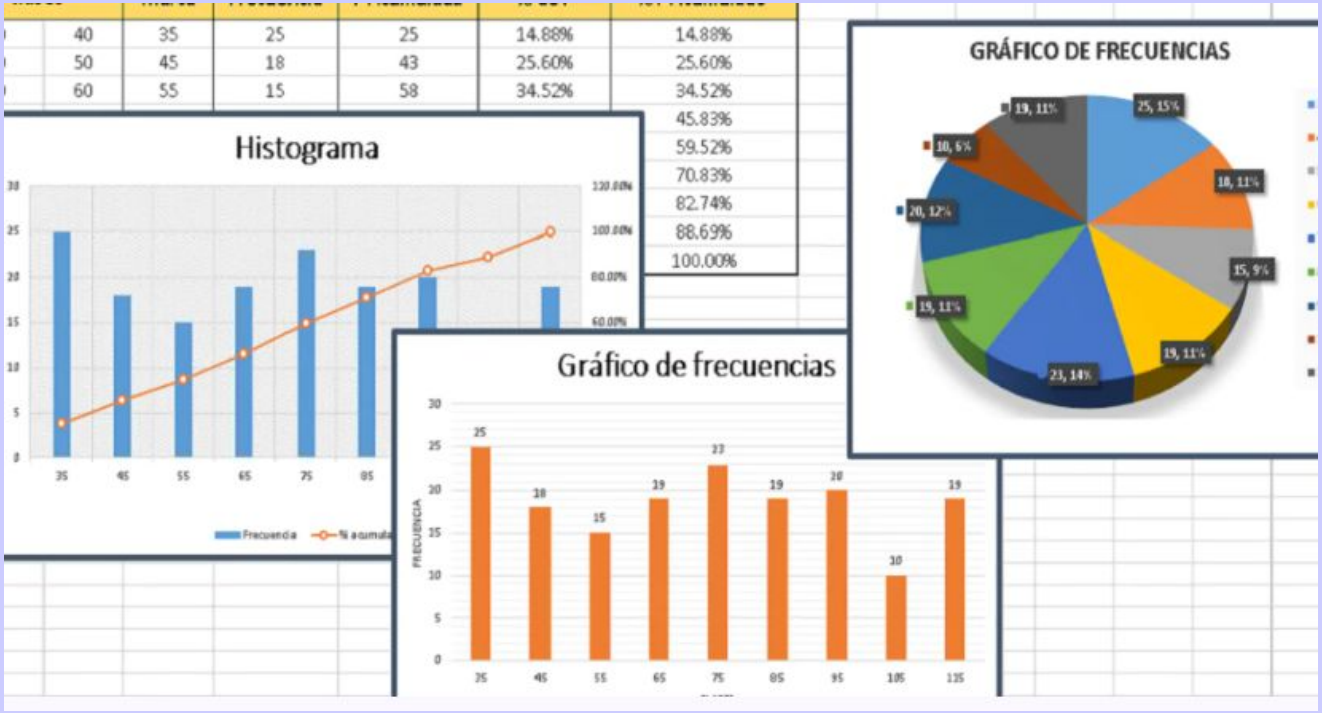
4. Compresión del Modelo

- Involucra varios aspectos como:
  - ***Resumen del Modelo***: debe mostrar los pesos, frecuencias, y conjunciones que son importantes para describir la meta. Debe ser entendible y conciso
  - ***Distribución de Datos***: un modelo es útil solo si esta basado en una muestra lo suficientemente grande. Si un conjunto de datos posee 1 millón de hombres y solo una mujer, no va a ser un estudio válido para mujeres.

El proceso para MD

4. Compresión del Modelo

- Distribución de los datos



El proceso para MD

4. Compresión del Modelo

- ***Diferenciación***: si una entrada o criterio predice de igual forma dos resultados, luego estos criterios no son útiles.

  Por ejemplo si tenemos que a los jóvenes pueden frecuentar McDonald pero también pueden frecuentar Burger King no es útil. En cambio si una entrada predice una salida mucho mejor que otra, esta posee un grado alto de diferenciación. Por ejemplo las personas con zapatos rojos y pelo corto son 10 veces mas propensas a elegir McDonald que Burger King. Este criterio si posee un alto grado de diferenciación

- ***Validación***: es la tarea de hacer predicciones usando el modelo creado y comparándolo con los resultados reales.

  Por ejemplo, comparar lo que realmente sucedió con los clientes con lo que habíamos predecido.

El proceso para MD

- **Modelos de Minería de Datos**
  - ***Árboles de Decisión:*** Dividen la información en forma de árbol de acuerdo a pesos.
  - ***Algoritmos Genéticos:*** Se basan en la evolución biológica seleccionando la especie más apta
  - ***Redes Neuronales:*** Se basan en la simulación del sistema nervioso de los seres vivos

El proceso para MD

- **Modelos de Minería de Datos**
  - ***Árboles de Decisión:***
    - debemos clasificar conjuntos de datos,
    - debemos predecir las salidas
    - el objetivo es generar reglas que son fáciles de explicar y traducir en SQL o en un lenguaje natural

El proceso para MD

- **Modelos de Minería de Datos**
  - ***Redes Neuronales:***
    - los resultados del modelo son mas importantes que entender como el modelo trabaja
    - no se necesitan extraer reglas
    - cuando usamos clustering (la red identificará grupos de datos similares, pero no explicará cómo lo son)
    - cuando la cantidad de entradas es limitada
  - ***Algoritmos Genéticos:***
    - tenemos problemas de optimización
    - hay parámetros específicos a optimizar y podemos encontrar una función de aptitud

El proceso para MD

- **Modelos de Minería de Datos**
  - Las Redes Neuronales pueden usarse junto con los Árboles de Decisión ya que los últimos sirven para elegir las variables de entrada más importantes y estas entradas serán usada para las redes
  - Los Algoritmos Genéticos están generalmente incluidos dentro de otros paquetes. Las Redes Neuronales utilizan Algoritmos Genéticos para mejorar su rendimiento

El proceso para MD

5. Uso del Conocimiento Descubierto

- Se trata de qué hace la organización con los resultados de haber aplicado el proceso completo.



Minería en la Web

- **Web Content Mining:** extraer información del contenido de los documentos en la web. Se puede clasificar a su vez en:
  - Text Mining: si los documentos son textuales (planos),
  - Hypertext Mining: si los documentos contienen enlaces a otros documentos o a sí mismos,
  - Multimedia Mining: para imágenes, audio, vídeo, etc.
- **Web Structure Mining:** se intenta descubrir un modelo a partir de la topología de enlaces de la red. Este modelo puede ser útil para clasificar o agrupar documentos
- **Web Usage Mining:** se intenta extraer información (hábitos, preferencias, etc. de los usuarios o contenidos y relevancia de documentos) a partir de las sesiones y comportamientos de los usuarios y navegantes.